

Coding Scheme for Converting German Annual Reports (PDF)
into LLM-Optimized Markdown
Ground Truth — October 2025

HiWi Project

October 29, 2025

Contents

1 Introduction **2**

1.1 Purpose and Scope 2

2 Core Structural Elements **2**

2.1 Document Metadata 2

2.1.1 Main Sections of a German Annual Report 3

2.2 Page Marking System 4

3 Heading Hierarchy Standards **4**

3.1 Overview 4

3.2 Quick Decision Guide 4

4 Number and Unit Standardization **5**

4.1 Rules 5

4.2 Standard Unit Tags 5

5 Footnote System **6**

5.1 Structured Footnote Annotation 6

5.2 Footnote Types 6

6 Table Formatting **7**

6.1 Core Rules (for Markdown) 7

7 Complete Example Template **8**

7.1 Special Cases in Tables 9

7.2 Special Case: Page Breaks within Continuous Text 10

1 Introduction

This manual describes a standardized coding scheme for converting German annual reports (PDF) into structured Markdown format optimized for Large Language Model (LLM) training. The scheme creates high-quality ground truth that enables LLMs to answer precise questions about annual reports with accurate page references.

1.1 Purpose and Scope

The ground truth will be used to train LLMs for:

- Extracting Key Audit Matters from audit opinions
- Answering financial questions with exact page references
- Understanding the structure and content of German annual reports
- Providing precise numerical information with proper context

The scheme prioritizes **machine readability** over visual aesthetics.

2 Core Structural Elements

2.1 Document Metadata

Each sample starts with YAML metadata describing only the covered content.

YAML header example

```
---
document_meta:
  company: "BMW AG"
  year: 2024
  document_type: "annual_report"
  language: "de"
  pages_covered: [89, 90, 91]
  sections: ["audit_opinion", "key_audit_matters", "footnotes"]
---
```

Why sections? Annual reports are divided into clearly defined sections because key parts are *legally required* and *audited*. Under German and EU law, companies must include financial statements with notes and an auditor's report, a management report, and—since CSRD/ESRS—sustainability disclosures. Additional elements such as a corporate governance declaration, financial calendar or imprint are also common. The schema reflects these mandatory and recurring parts to ensure consistent section mapping across reports.

2.1.1 Main Sections of a German Annual Report

Section Type	Description English (German)	H-Level
management_report	Management Report (Lagebericht)	H1
consolidated_financial_statements	Consolidated Financial Statements (Konzernabschluss)	H1
notes	Notes to the Consolidated Financial Statements (Konzernanhang)	H1
audit_opinion	Auditor's Opinion (Bestätigungsvermerk)	H1
sustainability	Sustainability / ESG Report (Nachhaltigkeitsbericht – CSRD / ESRS)	H1
corporate_governance	Corporate Governance Declaration (Erklärung zur Unternehmensführung)	H1
financial_calendar	Financial Calendar / Key Dates (Finanzkalender)	H1
imprint	Imprint / Contact Information (Impressum)	H1
consolidated_balance_sheet	Consolidated Balance Sheet (Konzernbilanz)	H2
income_statement	Income Statement (Konzern-Gewinn- und Verlustrechnung)	H2
cash_flow_statement	Cash Flow Statement (Kapitalflussrechnung)	H2
statement_of_changes_in_equity	Statement of Changes in Equity (Eigenkapitalveränderungsrechnung)	H2
accounting_policies	Accounting Policies (Bilanzierungs- und Bewertungsmethoden)	H2
segment_reporting	Segment Reporting (Segmentberichterstattung)	H2
business_development	Business Development (Geschäftsverlauf)	H2
financial_position	Net Assets, Financial Position and Results of Operations (Vermögens-, Finanz- und Ertragslage)	H2
risk_and_opportunity_report	Risk and Opportunity Report (Chancen- und Risikobericht)	H2
outlook	Outlook / Forecast Report (Prognosebericht)	H2
research_and_development	Research & Development (Forschung und Entwicklung)	H2
employees	Employees / Workforce (Mitarbeiterbericht)	H2
subsequent_events	Subsequent Events (Nachtragsbericht)	H2
key_audit_matters	Key Audit Matters (Besonders wichtige Prüfungssachverhalte)	H2
footnotes	Structured Footnotes Section (Fußnotenabschnitt)	H2

2.2 Page Marking System

- **P1** Each PDF page is marked with [PAGE:X] at the beginning.
- **P2** Page markers appear before any page content.
- **P3** Example: [PAGE:127].
- **P4** Multi-page content: [SECTION:KAM_DEV_COSTS|PAGES:128-129].

3 Heading Hierarchy Standards

3.1 Overview

Level	Syntax	Purpose
H1	#	Main section / independent chapter (e.g., # KONZERNABSCHLUSS)
H2	##	Functional area within a main section (e.g., ## KEY AUDIT MATTERS)
H3	###	Specific topic (e.g., ### Bewertung von Entwicklungskosten)
H4	####	Detailed aspect (e.g., #### Prüfungsrisiko)
H5	#####	Fine subdivision (rarely used)

3.2 Quick Decision Guide

Question / Content Type	Choose Level
Separate report or major document division?	H1
Functional purpose (data, analysis, report area)?	H2
Specific subject or audit focus?	H3
Detail of a topic (method, risk, data)?	H4
Individual line item / formula (rare)?	H5

4 Number and Unit Standardization

4.1 Rules

- Apply all formatting rules consistently in both **tables and text passages**.
- Remove thousand separators (e.g., “3.209.776” → 3209776 [EUR]).
- Normalize all units in brackets: [MIO], [EUR], [PERCENT].
- Use parentheses for negative values: (123 [MIO]).
- Standardize percentages to dot-decimal format (e.g., “2,05 %” → 2.05 [PERCENT]).

4.2 Standard Unit Tags

German Original	Tag	Meaning
Mio. EUR, Mio.	[MIO]	Million EUR
Mrd. EUR, Mrd.	[MRD]	Billion EUR
TEUR, in TEUR	[TEUR]	Thousand EUR
EUR, Euro	[EUR]	Euro (base unit)
% , Prozent	[PERCENT]	Percentage
Anzahl, Stück	[COUNT]	Count/Number
Tage	[DAYS]	Days
Jahre	[YEARS]	Years
Aktien	[SHARES]	Number of shares
BOE	[BOE]	Barrels of oil equivalent
KBOE	[KBOE]	Thousand BOE
USD Mio.	[USD_MIO]	Million USD
GBP Mio.	[GBP_MIO]	Million GBP
Quadratmeter	[SQM]	Square meter
USD, US-Dollar	[USD]	US Dollar
PLN, Polnischer Złoty	[PLN]	Polish Zloty
Tonnen, t	[TON]	Metric tons
EUR je Aktie	[EUR_PER_SHARE]	Euro per share
Mitarbeiter	[EMPLOYEES]	Employees

Table 4: Standard Unit Tags used in the coding scheme

Das gezeichnete Kapital setzte sich am Bilanzstichtag aus 60.097.000 auf den Inhaber lautenden Stückaktien zusammen mit einem rechnerischen Anteil jeder Aktie am Grundkapital von 2,69 €. Mit allen Aktien sind die gleichen Rechte und Pflichten verbunden. Diese ergeben sich aus den Vorschriften des Aktiengesetzes.

Beschränkungen, die Stimmrechte oder die Übertragung von Aktien betreffen, bestanden am Bilanzstichtag nach Kenntnis des Vorstandes nur insoweit, als der Gesellschaft aus den von ihr gehaltenen eigenen Aktien (6.009.700 Stück) keine Stimmrechte zustanden und als Vorstands- und Aufsichtsratsmitgliedern aus von ihnen gehaltenen Aktien kein Stimmrecht bei der Beschlussfassung über ihre eigene Entlastung zustand.

Eine Beteiligung am Kapital von mehr als 10% der Stimmrechte bestand am Bilanzstichtag nur seitens der Hannoversche Beteiligungsgesellschaft Niedersachsen mbH (HanBG), Hannover, die gemäß ihrer Mitteilung vom 2. April 2002 mit 25,5% der Stimmrechte an der Salzgitter AG beteiligt ist; dies entsprach infolge der seitdem gesunkenen Anzahl der insgesamt ausgegebenen Aktien am Bilanzstichtag einem Stimmrechtsanteil von 26,5%. Alleiniger Gesellschafter der HanBG ist das Land Niedersachsen.

Figure 1: Example of standardized table formatting (I)

Das gezeichnete Kapital setzte sich am Bilanzstichtag aus 60097000 [SHARES] auf den Inhaber lautenden Stückaktien zusammen mit einem rechnerischen Anteil jeder Aktie am Grundkapital von 2.69 [EUR]. Mit allen Aktien sind die gleichen Rechte und Pflichten verbunden. Diese ergeben sich aus den Vorschriften des Aktiengesetzes.

Beschränkungen, die Stimmrechte oder die Übertragung von Aktien betreffen, bestanden am Bilanzstichtag nach Kenntnis des Vorstandes nur insoweit, als der Gesellschaft aus den von ihr gehaltenen eigenen Aktien (6009700 [SHARES]) keine Stimmrechte zustanden und als Vorstands- und Aufsichtsratsmitgliedern aus von ihnen gehaltenen Aktien kein Stimmrecht bei der Beschlussfassung über ihre eigene Entlastung zustand.

Eine Beteiligung am Kapital von mehr als 10 [PERCENT] der Stimmrechte bestand am Bilanzstichtag nur seitens der Hannoversche Beteiligungsgesellschaft Niedersachsen mbH (HanBG), Hannover, die gemäß ihrer Mitteilung vom 2. April 2002 mit 25.5 [PERCENT] der Stimmrechte an der Salzgitter AG beteiligt ist; dies entsprach infolge der seitdem gesunkenen Anzahl der insgesamt ausgegebenen Aktien am Bilanzstichtag einem Stimmrechtsanteil von 26.5 [PERCENT]. Alleiniger Gesellschafter der HanBG ist das Land Niedersachsen.

Figure 2: Example of standardized table formatting (II)

5 Footnote System

5.1 Structured Footnote Annotation

- **FN1:** Use standard Markdown footnote syntax with structured metadata.
- **FN2:** Include page reference and footnote type within the metadata tag.
- **FN3:** Example in text: EBITDA^[^1] or MITARBEITERZAHL^[^2].
- **FN4:** Define all footnotes with metadata at the end of the section under a FUSSNOTEN heading.

```
## FUSSNOTEN
[^1]: [FOOTNOTE:EBITDA_DEFINITION|PAGE:45|TYPE:CALCULATION]
Gewinn vor Zinsen, Steuern, Abschreibungen sowie
nichtzahlungswirksame IFRS-Aufwände für Management-Aktienoptionen.

[^2]: [FOOTNOTE:EMPLOYEE_COUNT|PAGE:45|TYPE:METHODOLOGY]
Im Durchschnitt des Geschäftsjahres.
```

5.2 Footnote Types

- **TYPE:CALCULATION** – Calculation methods (e.g., EBITDA definition)
- **TYPE:METHODOLOGY** – Measurement methodology (e.g., average headcount)
- **TYPE:ADJUSTMENT** – Adjustments to comparative figures
- **TYPE:REFERENCE** – Cross-references to other sections
- **TYPE:EXPLANATION** – General explanatory notes

6 Table Formatting

6.1 Core Rules (for Markdown)

- Use pipe syntax with header, separator and data rows.
- Highlight key figures with ****...****.
- Enclose negative values in parentheses.
- Always specify normalized units.
- Optional right alignment in Markdown: add : in separator.

Gewinn- und Verlustrechnung der Salzgitter AG (Kurzfassung)

in Mio. €	2020	2019
Umsatzerlöse	20,0	22,9
Erhöhung oder Verminderung des Bestandes an unfertigen Erzeugnissen	0,0	0,2
Sonstige betriebliche Erträge	12,6	15,8
Materialaufwand	0,0	0,2
Personalaufwand	24,5	34,7
Abschreibungen ¹⁾	5,8	5,3
Sonstige betriebliche Aufwendungen	27,2	41,4
Beteiligungsergebnis	19,9	59,8
Zinsergebnis	-5,9	-7,2
Steuern vom Einkommen und vom Ertrag	0,1	0,9
Ergebnis nach Steuern	-10,7	10,8
Sonstige Steuern	-1,4	-2,1
Jahresüberschuss/-fehlbetrag	-12,1	8,7

¹⁾inklusive Abschreibungen auf Finanzanlagen und Wertpapiere des Umlaufvermögens

Figure 3: Example of standardized Markdown table formatting

```
| **in Mio ** | **2020** | **2019** |
|-----|-----|-----|
| **Umsatzerlöse** | **20.0 [MIO]** | **22.9 [MIO]** |
| Erhöhung/Verminderung Bestand unfertiger Erzeugnisse | 0.0 [MIO] | 0.2 [MIO] |
| Sonstige betriebliche Erträge | 12.6 [MIO] | 15.8 [MIO] |
| Materialaufwand | 0.0 [MIO] | 0.2 [MIO] |
| Personalaufwand | 24.5 [MIO] | 34.7 [MIO] |
| Abschreibungen[1] | 5.8 [MIO] | 5.3 [MIO] |
| Sonstige betriebliche Aufwendungen | 27.2 [MIO] | 41.4 [MIO] |
| Beteiligungsergebnis | 19.9 [MIO] | 59.8 [MIO] |
| Zinsergebnis | (5.9 [MIO]) | (7.2 [MIO]) |
| Steuern vom Einkommen und vom Ertrag | 0.1 [MIO] | 0.9 [MIO] |
| **Ergebnis nach Steuern** | **(10.7 [MIO])** | **10.8 [MIO]** |
| Sonstige Steuern | (1.4 [MIO]) | (2.1 [MIO]) |
| **Jahresüberschuss / -fehlbetrag** | **(12.1 [MIO])** | **8.7 [MIO]** |

## FUSSNOTEN
[1]: [FOOTNOTE:DEPRECIATION_SCOPE|PAGE:70|TYPE:EXPLANATION]
Einschließlich Abschreibungen auf Finanzanlagen und Wertpapiere
des Umlaufvermögens.
```

7 Complete Example Template

```
---
document_meta:
  company: "BMW AG"
  year: 2024
  document_type: "annual_report"
  language: "de"
  pages_covered: [89, 90, 91]
  sections: ["audit_opinion", "key_audit_matters", "footnotes"]
---

[PAGE:89]
# BESTÄTIGUNGSVERMERK
## PRÜFUNGSURTEIL
### Grundlage für das Prüfungsurteil
Nach unserer Beurteilung entspricht der beigefügte Konzernabschluss...

## KEY AUDIT MATTERS
### Bewertung von Entwicklungskosten
[SECTION:KAM_DEV_COSTS|PAGES:89-90]
#### Prüfungsrisiko
Das Unternehmen aktiviert Entwicklungskosten von 5234 [MIO] EUR...
#### Prüfungshandlungen
- Nachvollziehbarkeit der IAS 38 Aktivierungsvoraussetzungen
- Werthaltigkeitstests für 2430 [MIO] EUR

[PAGE:90]
### Goodwill-Impairment-Test
#### Wesentliche Ermessensausübung
#### Prüfungshandlungen
- Mathematische Nachvollziehbarkeit der Modelle
- Plausibilisierung der Annahmen
```

7.1 Special Cases in Tables

In some cases, tables contain multiple header rows or headings that span across several columns. For the standardized Markdown format, the following rule applies:

- Always use the **topmost header row** as the basis for the column headings.
- Multi-line headers or merged columns (*merged headers*) should be simplified so that each column in the Markdown version receives a clear and unique heading.
- The objective is to maintain the **standardized table format** (fixed column structure with consistent, unambiguous headers).

FALKENSTEIN Nebenwerte AG Hamburg Anlagenspiegel zum 31. Dezember 2020									
	Anschaffungskosten				kumulierte Abschreibungen				
	Stand am 01.01.2020 EURO	Zugang EURO	Abgang EURO	Stand am 31.12.2020 EURO	Stand am 01.01.2020 EURO	Abschreibungen des Geschäftsjahres EURO	Stand am 31.12.2020 EURO	Buchwert am 31.12.2020 EURO	Buchwert am 31.12.2019 EURO
I. Sachanlagen									
Andere Anlagen, Betriebs- und Geschäftsausstattung	49.819,39	0,00	0,00	49.819,39	35.880,39	5.028,00	40.908,39	8.911,00	13.939,00
II. Finanzanlagen									
Wertpapiere des Anlagevermögens	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00	0,00
	49.819,39	0,00	0,00	49.819,39	35.880,39	5.028,00	40.908,39	8.911,00	13.939,00

Figure 4: Beispiel: Tabelle mit mehrzeiligen Spaltenüberschriften

```

**FALKENSTEIN Nebenwerte AG Hamburg**

## Anlagenspiegel zum 31. Dezember 2020

| **Position** | **Anschaffungskosten** | | | | **Kumulierte Abschreibungen** | | | | | |
|---|---|---|---|---|---|---|---|---|---|---|
| | **Stand 01.01.2020 [EUR]** | **Zugang [EUR]** | **Abgang [EUR]** | **Stand 31.12.2020 [EUR]** | **Stand 01.01.2020 [EUR]** | **Abschreibungen Geschäftsjahr [EUR]** | **Stand 31.12.2020 [EUR]** | **Buchwert 31.12.2020 [EUR]** | **Buchwert 31.12.2019 [EUR]** |
| **I. Sachanlagen** | | | | | | | | | |
| | Andere Anlagen, Betriebs- und Geschäftsausstattung | 49819.39 [EUR] | 0.00 [EUR] | 0.00 [EUR] | 49 819.39 [EUR] | 35880.39 [EUR] | 5028.00 [EUR] | 40908.39 [EUR] | 8911.00 [EUR] | 13939.00 [EUR] |
| **II. Finanzanlagen** | | | | | | | | | |
| | Wertpapiere des Anlagevermögens | 0.00 [EUR] | 0.00 [EUR] | 0.00 [EUR] | 0.00 [EUR] | 0.00 [EUR] | 0.00 [EUR] | 0.00 [EUR] | 0.00 [EUR] | 0.00 [EUR] |
| **Summe** | **49819.39 [EUR]** | **0.00 [EUR]** | **0.00 [EUR]** | **49819.39 [EUR]** | **35880.39 [EUR]** | **5028.00 [EUR]** | **40908.39 [EUR]** | **8911.00 [EUR]** | **13939.00 [EUR]** |

```

Figure 5: Beispiel

7.2 Special Case: Page Breaks within Continuous Text

If a paragraph or section continues across two pages, insert a [PAGE:X] marker at the **exact point** where the page break occurs. This marker ensures that text alignment and page referencing remain consistent even when no new heading appears.

- Place the marker directly at the start of the new page (before the first word).
- Do not repeat headings or section tags unless a new logical section begins.
- Use this only for continuous text, not for tables or figures (these have their own markers).
- Example illustrated below.

Aktien mit Sonderrechten, die Kontrollbefugnisse verleihen, existieren nicht. Am Kapital beteiligte Arbeitnehmer, die ihre Kontrollrechte nicht unmittelbar ausüben, sind dem Vorstand nicht bekannt.

Die Ernennung und Abberufung der Mitglieder des Vorstandes und die Änderung der Satzung erfolgen allein nach den Vorschriften des Aktiengesetzes.

Der Vorstand hat aufgrund von Beschlüssen der Hauptversammlung folgende drei Möglichkeiten, Aktien auszugeben oder zurückzukaufen:

- Er kann in der Zeit bis zum 31. Mai 2022 mit Zustimmung des Aufsichtsrates 30.048.500 neue auf den Inhaber lautende Stückaktien gegen Bar- oder Sacheinlagen ausgeben (Genehmigtes Kapital 2017), wobei unter Ausschluss des Bezugsrechts der Aktionäre nur bis zu 12.019.400 Stück (20% aller am 1. Juni 2017 ausgegebenen Aktien) ausgegeben werden dürfen. Die 20%-Grenze verringert sich um den anteiligen Betrag am Grundkapital auf den sich Optionen oder Wandlungsrechte beziehungsweise Optionen oder Wandlungsrechte auswirken.

Figure 6: Enter Caption

Aktien mit Sonderrechten, die Kontrollbefugnisse verleihen, existieren nicht. Am Kapital beteiligte Arbeitnehmer, die ihre Kontrollrechte nicht unmittelbar ausüben, sind dem Vorstand nicht bekannt.

Die Ernennung und Abberufung der Mitglieder des Vorstandes und die Änderung der Satzung erfolgen allein nach den Vorschriften des Aktiengesetzes.

[PAGE:71]

Der Vorstand hat aufgrund von Beschlüssen der Hauptversammlung folgende drei Möglichkeiten, Aktien auszugeben oder zurückzukaufen:

– Er kann in der Zeit bis zum 31. Mai 2022 mit Zustimmung des Aufsichtsrates 30048500 [SHARES] neue auf den Inhaber lautende Stückaktien gegen Bar- oder Sacheinlagen ausgeben (Genehmigtes Kapital 2017), wobei unter Ausschluss des Bezugsrechts der Aktionäre nur bis zu 12019400 [SHARES] (20 [PERCENT] aller am 1. Juni 2017 ausgegebenen Aktien)

Figure 7: Enter Caption